

항공사진 RSM 채널 캘리브레이션 재현 보고

Moon & Cho (2026), *Remote Sensing* 18:205 — Training-Free Lightweight Transfer Learning for Land Cover Segmentation Using Multispectral Calibration
이지안 · 동아대학교 AI학과 · 2026.09.19

요약

이 논문은 모델을 재학습하지 않고 입력 정규화 파라미터 6개(RGB 평균·표준편차)만 반응표면법으로 튜닝해, 도메인이 다른 항공사진에서 세그멘테이션 성능을 올리는 방법이다. 프랑스 FLAIR로 학습된 U-Net을 한국 AI-HUB 데이터에 적용해 침엽수 IoU 기준 최대 +67.86p 개선을 주장한다. FLAIR toy 데이터로 직접 재현한 결과, 베이스라인 저하(16.02%)와 보정 후 개선은 확인됐으나 논문이 가정한 볼록 단봉 반응면은 나타나지 않았고(정상점이 안장점), 최저값은 RSM 제안점이 아니라 랜덤 샘플에서 나왔다. 또한 논문 베이스라인이 모델 카드 권장 정규화를 쓰지 않아, 개선폭의 일부가 설정 복원 효과일 가능성을 확인 중이다.

1. 연구가 푸는 문제

배경 개념

시맨틱 세그멘테이션은 이미지의 픽셀 하나하나에 클래스 라벨을 붙이는 작업이다. 분류가 “이 사진에 건물이 있다”를 답한다면, 세그멘테이션은 “이 픽셀은 건물, 저 픽셀은 물”이라고 지도를 그린다. 토지피복 분류는 항공사진을 입력받아 건물·도로·숲·물의 지도를 만드는 일이라 여기에 해당한다.

도메인 시프트는 학습 지역과 적용 지역의 픽셀 값 분포가 다른 현상이다. 논문은 프랑스가 해양성·지중해성·대륙성 기후가 섞인 온화한 조건인 데 비해 한국은 덥고 습한 여름을 가져, 같은 침엽수림이어도 엽록소 활성과 RGB 통계가 다르다고 설명한다.

전이학습은 학습된 모델을 새 환경에 맞추는 일이다. 통상적인 파인튜닝은 새 지역 라벨 수천 장으로 가중치를 다시 학습시키므로, 라벨 제작 비용과 GPU가 실사용의 장벽이 된다.

논문의 목표

모델 가중치를 전혀 건드리지 않고(training-free), 라벨 30~150장과 일반 CPU만으로 새 지역 성능을 끌어올리는 것이다. 논문이 내세우는 수치는 아래와 같다.

항목	논문이 보고한 값
실험 E1 침엽수 IoU	13.57% → 81.43% (+67.86p)
최적화에 쓴 타일	32~150장
연산 자원	풀 학습 대비 4000배 이상 절감 주장

2. 핵심 아이디어: 정규화 값을 튜닝한다

딤러닝 모델은 이미지를 그대로 받지 않고 정규화를 거친다. 채널별로 적용하므로 RGB이면 평균 3개와 표준편차 3개, 모두 여섯 개의 숫자다. 보통은 학습 때 쓴 값으로 고정해두는 상수다.

정규화된 입력 = (픽셀값 - mean) / std

mean : R, G, B 3개

std : R, G, B 3개 합계 6개

논문은 이 여섯 개를 튜닝 대상 하이퍼파라미터로 본다. 값을 바꾸면 모델이 보는 이미지의 밝기와 대비가 달라져, 입력을 모델이 학습한 분포 쪽으로 옮길 수 있다. 가중치를 재학습하는 대신 입력을 모델 쪽으로 옮기는 접근이므로 GPU가 필요 없고 추론만 반복하면 된다.

3. 데이터셋 구조

FLAIR (프랑스 IGN)

직접 내려받아 확인한 구조다. 패치는 5밴드 TIF이고 앞 3개가 RGB다.

flair_1_toy_dataset/ flair_1_toy_aerial_train/D004_2021/Z1-UA/img/IMG_000717.tif flair_1_toy_labels_train/D004_2021/Z1-UA/msk/MSK_000717.tif
--

항목	값
패치 크기	512 × 512 픽셀, uint8
해상도(GSD)	0.20 m
밴드	5개 — R, G, B, NIR, Elevation
전체 규모	77,412 패치 (학습용 218,400 패치)
좌표계	EPSG:2154
클래스	19개

폴더 이름의 D번호는 프랑스 행정구역(département) 단위 도메인이다. 논문은 D004와 D067을 서로 다른 도메인으로 놓고 전이 실험을 한다. 하위 Z 폴더는 촬영 존이고, 존 하나당 약 100패치다.

도메인	위치	기후	경관
D004	남부	지중해성	농지·관목·숲 혼재
D067	북동부	습윤대륙성	도시·산업·농업 평지

마스크 구조와 클래스

마스크는 값이 1부터 19까지인 정수 배열이다. 아래 비율은 toy 데이터 20타일에서 직접 집계했다.

값	클래스	확인된 비율	값	클래스	확인된 비율
1	building	5.35%	7	deciduous	17.20%
4	bare soil	17.29%	10	herbaceous	10.68%
6	coniferous	15.29%	기타	표에 없는 값 포함	—

전체 19개 클래스는 building, pervious surface, impervious surface, bare soil, water, coniferous, deciduous, brushwood, vineyard, herbaceous, agricultural land, plowed land, swimming pool, snow, clear cut, mixed, ligneous, greenhouse, other다. 이 중 15 clear cut, 16 mixed, 17 ligneous, 19 other는 학습에서 가중치 0으로 비활성화돼 모델이 예측하지 않는다.

AI-HUB (한국)

항목	UAV(드론)	항공
해상도(GSD)	0.12 m	0.25 m
패치 수	900	45,000
밴드	RGB 3개	RGB 3개
좌표계	EPSG:5186	EPSG:5186
클래스	12개	12개

클래스 매핑: 토지피복과 토지이용

두 데이터의 분류 기준 자체가 다르다. FLAIR는 표면에 무엇이 있는지를 보는 토지피복(LC) 기준이고, AI-HUB는 법적·기능적 용도인 토지이용(LU)이 섞여 있다. 예를 들어 “주차장”은 아스팔트일 수도, 흙일 수도 있다. 그래서 1:1 매핑이 되는 것은 물리적 성질로 정의된 5개뿐이다.

구분	해당 클래스	사유
매핑 가능 (5개)	건물, 온실, 활엽수, 침엽수, 수체	물리적 성질로 정의돼 분광 특성이 일관
제외	도로, 주차장, 나대지	용도 기준이라 물리적으로 이질적
제외	논, 밭	계절마다 물·식생·맨땅으로 변동

4. 모델

논문은 공개된 사전학습 모델을 그대로 쓴다. 새로 만들지 않는 것이 이 연구의 전제다.

모델	구조	출처
FLAIR U-Net (ResNet34)	U-Net + ResNet34 인코더	IGN
FLAIR U-Net (MiT-B5)	U-Net + Mix Transformer 인코더	IGN
AI-HUB U-Net	U-Net	AI-HUB

U-Net은 이미지를 줄이며 특징을 뽑는 인코더와 원래 크기로 키우며 픽셀별 라벨을 만드는 디코더가 U자로 이어진 구조다. 중간을 잇는 연결(skip connection) 덕에 경계가 선명하게 나온다. 백본이 무엇이나가 논문의 논점인데, ResNet34는 CNN 계열이고 MiT-B5는 트랜스포머 계열로 구조가 완전히 다르다. 논문은 ResNet34에서 찾은 최적값을 MiT-B5에 그대로 써도 성능이 오른다는 것을 근거로, 이 방법이 특정 모델 내부 구조가 아니라 지표면의 물리적 반사 특성을 잡아낸다고 주장한다.

재현에는 FLAIR-INC rgb 15cl resnet34-unet 공개 가중치를 사용했고, 출력이 19채널임을 확인했다.

5. 방법론: 반응표면법과 평가지표

반응표면법(RSM)

원래 화학공정이나 제조업 최적화에서 쓰는 통계 기법이다. 실제 함수 모양은 모르지만 최적점 근처에서는 2차 곡면에 가깝다고 가정하고, 몇 번 실험해 2차식을 피팅한 뒤 미분해서 기울기가 0인 지점을 구한다.

항목	이 논문에서의 설정
독립변수	RGB의 평균·표준편차 6개
종속변수	그 설정으로 추론했을 때의 클래스별 IoU
	2

계수 개수	상수 1 + 1차항 6 + 2차·교차항 21 = 28 (최소 관측 수)
실제 추론 횟수	클래스당 40~60회

논문이 RSM을 정당화하는 논리는, 토지피복이 자연현상이라 온도·토양·식생이 공간적으로 급변하지 않고 매끄럽게 변하므로 반응면도 매끄럽고 봉우리가 하나인(단봉) 볼록 형태일 것이라는 주장이다.

평가지표: IoU

IoU = TP / (TP + FP + FN)

Accuracy는 전체 픽셀 중 맞힌 비율이라 면적이 큰 클래스만 잘 맞혀도 높게 나온다. AI-HUB는 미분류 영역이 20% 가까이 돼 왜곡이 특히 크다. IoU는 클래스별로 계산하므로 작은 클래스가 묻히지 않는다.

6. 알고리즘

단계	내용
1. 클래스 매핑	두 데이터의 라벨 체계를 맞추고, 의미가 대응되는 클래스만 비교 대상으로 남긴다.
2. 타깃 타일 선정	대상 클래스가 실제로 존재하는 타일만 최적화에 쓴다. E1은 100타일 중 32타일.
3. 1단계 탐색	기준값 주변을 넓게 흔들어가며 약 30회 추론하고 매번 IoU를 기록한다.
4. 2차 회귀 피팅	모인 (6개 값, IoU) 쌍에 2차식을 맞춘다.
5. 정상점 계산	각 변수로 편미분해 전부 0이 되는 연립방정식을 푼다. 이것이 예상 최적점이다.
6. 2단계 탐색	그 근처를 좁은 범위로 10~20회 더 샘플링하고 재피팅한다. R²가 0.9를 넘거나 개선이 멈추면 종료한다.
7. Decision fusion	클래스마다 최적값이 다르므로 클래스별로 추론한 뒤 픽셀 단위로 합친다. 확률이 높은 클래스가 아니라 보정으로 IoU가 많이 오른 클래스를 우선한다.

비례 전이

한 지역에서 찾은 값을 다른 지역에 옮길 때 절대값이 아니라 비율을 옮긴다.

$$\theta(A, \text{예측}) = \theta(A, \text{기본}) \times \theta(B, \text{최적}) / \theta(B, \text{기본})$$

예: B에서 최적 R_mean이 기본값의 1.03배였다면
A에서도 A의 기본 R_mean에 1.03을 곱한다

지역마다 기본 분포는 다르지만 곡면의 모양과 봉우리의 상대 위치는 같다는 가정이다. 저자들은 어느 데이터에서든 최적 비율이 R↓ G↑ B↓ 패턴으로 일관되게 나왔다는 관찰을 근거로 들고, 여기서 CNN 가중치가 입력 스펙트럼 특성에 비례하는 구조화된 매니폴드를 이룬다는 해석까지 확장한다.

7. 한계

논문이 인정한 것

항목	내용	근거 수치
반응면 불안정	저성능 클래스에서 스펙트럼 변화에 대한 반응이 일정하지 않다	E2 Adj.R² 0.706, E3b 0.771
라벨 품질 제약	가로수가 심긴 도로·주차장이 정답에서 “기타”로 처리됐다	E3a 가로수 +1.79p
해상도 의존	드론 영상이 항공 영상보다 보정 효과가 크다	12 cm 대 25 cm

논문은 낮은 결정계수를 데이터 품질의 진단 지표로 해석하지만, 뒤집으면 RSM 가정이 깨지는 경우가 실제로 있다는 뜻이다.

검토에서 확인된 문제

항목	내용
평가 누수	최적값 탐색과 결과 보고가 같은 타일에서 이루어져 별도 테스트셋 검증이 없다.
다른 클래스 희생	E4 농경지 −19.74p, E1 활엽수는 공식 성능 대비 −15p. “trade-off 없음”은 과장이다.
결론의 비약	입력 색 보정에 대한 반응이 매끄럽다는 관찰에서 CNN 내부 표현 구조까지 결론을 확장한다.
수치 불일치	표 9 본문 115.87 대 표 116.87(식 4로 계산하면 표가 맞다), 표 11의 80.35 대 표 5의 81.43, E3의 IoU·accuracy 혼용.
비용 비교	비교 대상 연구들의 태스크, 클래스 수, 데이터가 서로 달라 공정한 비교가 아니다.

8. 직접 재현한 결과

재현 환경

항목	값
데이터	FLAIR toy 60타일 (전체 [__]타일 중, 선정 기준 [__])
모델	FLAIR-INC rgb 15cl resnet34-unet, 출력 19채널
타깃 클래스	침엽수 (마스크 값 6 → 모델 인덱스 5)
타일 분할	calib 15 / test 7 / all 60
탐색 횟수	40회
연산 환경	CPU [__], 실행 시간 [__]

논문과 달리 캘리브레이션 타일과 테스트 타일을 7:3으로 분리한 것이 이 재현의 차이점이다.

재현된 것

구분	base	best	fusion
calib (15타일)	16.02	31.74	32.39
test (7타일)	22.44	58.52	58.45

베이스 침엽수 IoU 16.02%는 논문 E2의 13.36%와 가깝다. 모델 공식 성능이 55~56%인데 이미지 통계로 정규화하면 크게 떨어지는 현상이 실재한다. 탐색에 쓰지 않은 타일에서도 22.44 → 58.52로 올라, 누수 때문에 생긴 착시만은 아니라는 증거가 된다. 또한 최적값만 적용하면 수영장 48 → 26, 눈 66 → 16으로 떨어지고 전체 mIoU가 51.26 → 46.13이 되지만, decision fusion을 적용하면 52.35로 회복된다. 논문이 fusion을 쓰는 이유가 확인된 셈이다.

재현되지 않은 것

항목	재현 결과
정상점 성격	안장점(saddle)으로 나왔다. 논문이 가정한 볼록 단봉 반응면이 아니다.
예측 정확도	RSM 예측 45~48% 대 실제 17%, 오차 28~31p.
최고 성능의 출처	RSM 제안점이 아니라 10번째 랜덤 샘플에서 나왔다.
모형 적합도	R² 0.95지만 관측 40개에 계수 28개를 맞춘 과적합이고, Adj.R²는 0.83으로 떨어진다.
최적 비율 패턴	R ↓ G ↑ B ↑ 로, 논문의 R ↓ G ↑ B ↓와 다르다.

확인 중인 의문

모델 카드는 학습에 쓴 통계를 추론에도 쓰라고 권장하지만, 논문의 베이스라인은 이미지 자체 통계를 쓴다.

기준	R, G, B 평균	R, G, B 표준편차
모델 카드 권장값	105.08, 110.87, 101.82	52.17, 45.38, 44
재현에서의 이미지 통계	112.55, 115.17, 108.35	55.79, 48.58, 45.76

판단 보류

권장값을 시작점으로 두고 첫 추론의 IoU를 측정하면, 개선폭 중 얼마가 설정 복원 효과인지 분리할 수 있다. 그 값이 50% 근처면 논문의 극적 개선은 대부분 잘못된 베이스라인 탓이라는 결론이 되고, 20% 이하면 도메인 차이가 진짜 원인이라는 뜻이 된다. 이 확인이 끝나기 전까지는 재현 성공 여부를 단정하지 않는다.

9. 응용 방향

방향	내용
평가 프로토콜 정비	calib/test 분리와 공식 정규화 베이스라인을 추가해 RSM 자체의 기여분을 분리한다. 현재 진행 중인 작업이다.
탐색 방법 교체	안장점 문제에 대응해 베이지안 최적화나 CMA-ES를 쓰고, 추론 횟수 대비 성능으로 비교한다.
도메인 갭 지표 연결	논문이 쓴 JSD로 도메인 차이를 재고, 갭이 클수록 효과가 큰지 여러 도메인 쌍에서 검증한다.
한국 데이터 적용	AI-HUB 데이터로 실험 E1을 재현해 논문의 한국 데이터 주장을 직접 확인한다.