

9/29 RSM Calibration 보고서

1. 9/22 교수님 피드백과 진행 현황

피드백	내용	상태
2차방정식(RSM 모델) 분석	식이 어떻게 만들어졌는지, 왜 2차인지(1차·3차·4차는 왜 아닌지)	완료
Coefficient	계수를 어떻게 구하고 측정했는지, 어떻게 예측할 건지	일부 완료 (예측 방법은 향후 과제)
기존 방식과 논문 방식 차이	기존: 픽셀·색 패턴 feature extraction → DNN / 논문: RGB mean·std 사용	완료
전체 데이터셋 실험	학교 GPU로 toy가 아닌 전체 데이터셋 실험	예정 (마지막 단계)

2. 기존 방식과 논문 방식 비교

기존 방식은 모델 가중치를 데이터로 다시 학습하고, 논문 방식은 가중치를 고정한 채 입력 정규화 값만 조정함. 아래는 논문 Table 13의 전이학습 분류.

	구조 변경 ○	구조 변경 X
새 데이터 학습 ○	전통 전이학습: 백본 재구성, 가중치 fine-tuning, feature extraction	데이터 확장: 도메인 적응, 참조 라벨 생성
새 데이터 학습 X	구조 최적화: 학습률 최적화, early stopping	경량 전이학습(이 논문): 추론 시 하이퍼파라미터 조정, 백본 재사용, 라벨 보정

- 기존 방식(픽셀·색 패턴 feature extraction → DNN)은 전통 전이학습에 해당
- 논문 방식은 모델 구조와 가중치를 고정하고 입력 정규화 값(RGB mean·std 6개)만 조정
- 필요한 데이터: 기존 방식은 수천 타일 이상의 라벨 데이터로 재학습(GPU), 논문 방식은 32~150 타일로 재학습 없이 일반 CPU에서 수행
- 논문 초록: 전체 학습 대비 계산 자원 4,000배 이상 절감

3. 논문 방식 개요

모델(FLAIR U-Net, ResNet34)은 그대로 두고, 입력 정규화 값 6개를 바꿔가며 대상 클래스(침엽수) IoU가 가장 높은 값을 찾음.

- 흐름: 항공사진 타일(RGB) → 정규화 (픽셀 - mean) / std → U-Net(가중치 고정) → 클래스별 IoU
- 조정 변수 $\theta = R \cdot G \cdot B$ mean 3개 + $R \cdot G \cdot B$ std 3개 = 6개
- $\theta_0 =$ 대상 타일 전체의 채널별 mean·std

탐색 순서 (논문 Figure 1):

1. θ_0 주변 30개 점에서 추론해 IoU 측정 (폭 $\text{adj}_0 \approx 0.5$)
2. 지금까지의 (θ , IoU) 기록 전체로 2차식 적합
3. 기울기 = 0인 정상점 $\hat{\theta}$ 계산 (식 3)
4. $\hat{\theta}$ 주변 5개 점에서 추론 (폭 0.1~0.2)
5. 개선이 없으면 종료, 아니면 2번으로

출력은 기록 중 IoU가 가장 높은 θ .

4. Q1. 논문과 동일하게 구현했지만 결과는 왜 달랐을까?

처음 구현은 데이터·보정 타일·기준 IoU 계산 방식이 논문 E2 조건과 달랐음. 세 가지를 고친 뒤 기준 IoU가 논문과 일치함.

항목	처음 구현	수정 후 (논문 E2 조건)
데이터	toy 250타일(train 200 + test 50) 중 침엽수 포함 65타일	toy test 50타일
보정에 쓴 타일	침엽수 포함 타일만	50타일 전체
기준 IoU 계산	타일마다 따로 정규화	50타일 전체 채널 통계 한 세트로 정규화

근거: 논문 E2는 toy 50타일(오라벨 3개 제외 47타일) 전체로 보정. test 폴더의 타일 수(50), 클래스 구성(1~13, 18, 19)이 일치.

기준 IoU 재현 (보정 전, 논문 Table 6 (b)와 비교)

침엽수 기준 IoU는 논문 13.36, 재현 13.34. 14개 클래스 모두 차이 ± 1.2 이내.

클래스	논문 IoU (%)	재현 IoU (%)	차이
building	79.39	79.42	+0.03
pervious	37.28	36.72	-0.56
impervious	70.72	70.85	+0.13

클래스	논문 IoU (%)	재현 IoU (%)	차이
bare soil	33.44	34.62	+1.18
water	76.70	77.42	+0.72
coniferous	13.36	13.34	-0.02
deciduous	49.58	49.48	-0.10
brushwood	22.33	22.16	-0.17
vineyard	62.58	62.87	+0.29
herbaceous	54.61	54.95	+0.34
agricultural	52.22	52.31	+0.09
plowed	40.71	40.94	+0.23
swimming pool	54.50	54.21	-0.29
greenhouse	0.38	0.30	-0.08

5. Q1. 수정 후에도 남아있는 문제

기준 IoU는 일치하지만 최적 IoU는 29.50으로 논문 75.24에 못 미침. 논문에 값이 없는 파라미터와 기술되지 않은 절차가 원인 후보.

5-1. 논문에 값이 명시되어 있지 않은 파라미터

항목	논문 표기	적용 값
탐색 폭 adj	1단계 0.5, 이후 0.1~0.2 (단위 없음)	기준 대비 $\pm 50\%$, 이후 $\pm 15\%$
주변 점 생성 방식	Neighborhood()	LHS(고르게 흩뿌리기), seed 0
회차당 점 개수	$n_{\min} \approx 5$	중심 포함 5개

- 논문에서 제외한 오라벨 타일 3개는 목록 미공개. 50타일 중 3개를 냈다고만 기재. 기준 IoU 차이가 ± 1.2 이내라 영향은 작음.
- 본문은 클래스당 40~50회 추론이라고 쓰지만, Table 10 통계값으로 역산한 E2 관측 수는 125개 (5-3).
- 본문의 " $R^2 \geq 0.9$ 까지 반복" 조건은 Figure 1 알고리즘에 없음.

5-2. 탐색 폭·관측 수를 바꾼 실험

조건: toy test 50타일, 침엽수, 논문 Figure 1 방식.

	논문 E2	$\pm 50\%$	$\pm 10\%$	$\pm 50\%$, 125회
기준 IoU	13.36	13.34	13.34	13.34
최적 IoU	75.24	29.50	29.34	29.50
추론 횟수	40~50 (본문)	35	35	125
R^2	0.770	0.941	0.986	0.546

- 탐색 폭($\pm 10\%$, $\pm 50\%$)과 관측 수(35, 125)를 바꿔도 최적 IoU는 29.3~29.5.
- 세 실행 모두 최적 IoU는 1단계 무작위 샘플에서 나왔고, 정상점은 매번 안장점(saddle).

5-3. 논문 통계값 역산

R^2 , $\text{Adj.}R^2$, F, p-value는 관측 수(n)와 계수 수(p)로 정해짐. 네 값으로 n, p를 거꾸로 계산함.

실험	R^2	$\text{Adj.}R^2$	F	p-value	역산 (관측 수, 계수 수)
E1	1.000	0.999	985.9	1.01×10^{-3}	(7, 5)
E2 (toy)	0.770	0.706	12.03	1.55×10^{-20}	(125, 28), 네 값 모두 일치
E3a	0.972	0.968	269.9	1.54×10^{-147}	(≈ 238 , 28)
E3b	0.792	0.771	38.48	2.55×10^{-77}	(≈ 301 , 28)
E4	0.984	0.973	83.99	3.44×10^{-25}	($\approx 63 \sim 65$, ≈ 28)
E5	0.992	0.986	156.7	4.24×10^{-27}	($\approx 60 \sim 62$, ≈ 28)

- E2 회귀식은 관측 125개로 적합한 결과와 일치. 본문 기재는 클래스당 40~50회 추론.
- E1은 논문 식(계수 28개)으로는 나올 수 없는 조합.
- 같은 관측 수 125개로 실행한 재현 결과: R^2 0.546, 최적 IoU 29.50.

5-4. Q1 정리

논문과 일치	논문과 불일치
데이터: toy test 50타일	최적 IoU: 29.50 (논문 75.24)
모델: FLAIR U-Net(ResNet34), 모델 카드 침엽수 IoU 56.07 일치	R^2 : 0.546 (논문 0.770, 관측 125개 기준)
기준 IoU: 14개 클래스 ± 1.2 이내	탐색 폭·관측 수를 바꿔도 29.3~29.5

논문과 일치	논문과 불일치
알고리즘: Figure 1 단계, 식 1~3 검증	

차이의 원인 후보는 두 가지. 논문에 값이 없는 파라미터(탐색 폭 단위, 샘플 생성 방식, seed)와, 논문에 기술되지 않은 절차(본문 40~50회 vs 통계 역산 125개).

6. 2차방정식(RSM 모델)과 계수

논문 식 1은 변수 6개(R·G·B mean, R·G·B std)로 만들 수 있는 2차 이하 항을 모두 포함하고, 계수는 28 개.

$$IoU = \beta_0 + \sum \beta_i x_i + \sum \sum \beta_{ij} x_i x_j$$

6-1. 식의 구조

항	개수	의미
상수	1	기준 높이
1차항	6	변수별 기울기 (Rm, Gm, ...)
제곱항	6	휘어진 정도, 음수면 위로 볼록
교차항	15	두 변수를 같이 바꿀 때의 효과, 6개 중 2개 = ${}_6C_2$
합계	28	최소 관측 수 (논문 식 2)

차수를 올리면 필요한 계수 수가 빠르게 늘어남. 변수 수 d, 차수 k일 때 계수 수는 $(d + k)! / (d! \cdot k!)$.

차수 (교차항 포함)	1차	2차	3차	4차
계수 수	7	28	84	210

6-2. 계수를 구하는 방법: 최소제곱

측정한 IoU와 식이 계산한 IoU의 차이가 가장 작아지도록 계수를 정함.

1. θ 를 바꿔가며 모델 추론 $\rightarrow$ 각 θ 에서 IoU 측정 $\rightarrow (\theta, IoU)$ 기록
2. 오차제곱합 계산: $\sum (\text{측정 IoU} - \text{식의 IoU})^2 (= \text{MSE} \times n)$
3. 오차제곱합이 가장 작은 계수 선택 (정규방정식)

$$\beta = (A^T A)^{-1} A^T y$$

A는 행 = 측정점, 열 = 식의 각 항 값. y는 측정 IoU.

예시(변수 1개, 측정점 4개)에서 오차제곱합은 1차 91.33, 2차 4.31, 3차 0.00. 3차식은 계수 4개로 점 4개를 정확히 통과하므로, 측정 데이터 오차로는 차수를 비교할 수 없음. 그래서 Q2에서는 LOOCV를 사용함.

6-3. 계수의 측정·추정·예측

측정하는 것은 IoU이고, 계수는 측정값에서 계산(추정)하는 값.

단계	대상	방법
측정	IoU	θ 를 넣고 모델을 돌려 대상 타일의 IoU를 계산
추정	계수 β (28개)	측정한 (θ , IoU) 기록에 최소제곱으로 맞춰서 계산
예측	새 θ 의 IoU	계수가 정해진 식에 새 θ 를 대입

"coefficient를 어떻게 예측할 것인가"에 대해:

- 논문은 클래스·데이터마다 샘플링부터 다시 해서 계수를 새로 추정함.
- 다른 지역에 적용할 때는 계수가 아니라 최적 θ 의 비율(best / base)만 옮김 (논문 식 4).
- 샘플링 없이 새 데이터의 계수를 미리 예측하는 방법은 논문에 없음 → 향후 과제.

7. Q2. 왜 2차방정식이어야 할까?

1~4차 모델 중 예측 오차(LOOCV RMSE)가 가장 작은 것은 교차항을 포함한 2차식(논문 식 1)으로 6.79.

7-1. 가설과 구현

- 가설: 1~4차식으로 실험했을 때 2차식으로 도출한 예측값이 가장 정확해야 함
- 데이터: toy test 50타일, 침엽수, 논문 방식 125회 실행 기록 (θ , IoU) 125개
- 같은 데이터에 1~4차 모델을 각각 최소제곱으로 적합
- 3·4차는 교차항 없이 세제곱·네제곱항만 추가 (교차항 포함은 7-3)

비교 지표는 LOOCV RMSE. 점 하나를 빼고 → 나머지로 식을 적합하고 → 뺀 점의 IoU를 예측하고 → 125개 점 전부 반복해 평균 오차를 구함. R^2 는 계수가 많을수록 항상 커지므로 비교 기준으로 쓰지 않음.

7-2. 결과: 1~4차 비교

모델	계수	R^2	LOOCV RMSE
1차	7	0.136	7.73
2차 (교차항 없음)	13	0.283	7.51

모델	계수	R ²	LOOCV RMSE
3차 (교차항 없음)	19	0.338	7.89
4차 (교차항 없음)	25	0.408	9.00
2차 (교차항 포함, 논문 식 1)	28	0.546	6.79
평균값으로만 예측	1	-	7.91

교차항 포함 2차의 예측 오차가 가장 작음. 3·4차는 R²는 커지지만 예측 오차도 커짐.

7-3. 결과: 교차항을 넣은 고차 모델

2차식에 항을 더할수록 R²는 오르고 예측 오차도 오름.

모델	계수	잔차 자유도	R ²	Adj.R ²	LOOCV RMSE
2차 (교차항 포함, 논문 식)	28	97	0.546	0.420	6.79
2차 + 세제곱	34	91	0.658	0.534	7.66
2차 + 세제곱·네제곱	40	85	0.717	0.587	8.66
3차 (교차항 포함)	84	41	0.898	0.690	92.80
4차 (교차항 포함)	210	-	-	-	적합 불가 (계수 210개 > 관측 125개)

- 잔차 자유도 = 관측 수 - 계수 수 (계수를 추정하고 남은 여유 데이터)
- 3차(교차항 포함)는 R² 0.898로 측정 데이터에는 잘 맞지만, 처음 보는 θ 에서 오차 92.80 (IoU 범위 0~30)
- 10겹 교차검증으로 재확인: 2차 7.35, 3차 136.01

7-4. Q2 정리

- **2차가 필요한 이유:** IoU가 최대인 θ 를 찾으려면 봉우리를 표현해야 함. 1차는 평면이라 최대점이 없고, 2차는 최대점을 표현하는 가장 낮은 차수.
- **3·4차를 쓰지 않는 이유:** 계수 84개(3차), 210개(4차)는 관측 125개로 안정적 추정 불가. 교차항 없는 3·4차도 2차보다 예측 오차가 큼.
- **실험 결과:** 1~4차 중 예측 오차 최소는 2차(교차항 포함, 논문 식) 6.79.
- **한계:** 평균값 예측(7.91) 대비 오차 감소 14%, R² 0.546(논문 0.770). 참고로 $\pm 10\sim 25\%$ 의 좁은 범위 (65타일 데이터)에서는 1차가 더 정확했음.

8. 향후 계획

순서	항목	내용
1	AI-Hub 데이터 실험	한국 항공사진, AI-Hub 라벨 → FLAIR 클래스 매핑 후 같은 실험과 1~4차 비교
2	seed 반복	샘플 생성 seed를 바꿔 반복 실행, 결과가 우연인지 확인
3	전체 데이터셋 실험 (학교 GPU)	toy가 아닌 FLAIR 전체 데이터, D004·D067 지역 전이 (논문 E4·E5)
4	coefficient 예측 방법	샘플링 없이 새 데이터의 계수 또는 최적 θ 를 예측하는 방법 검토